Machine Learning un prognozēšanas modeļi

4. nedēļa: Kursa pārskats un gala projekts

Finansē Eiropas Savienība NextGenerationEU

2027 Nacionālais attīstības plāns

Projekts "Digitālo tehnoloģiju un procesu pārvaldības prasmju uzlabošana Latvijas uzņēmumos"
Nr. 2.3.1.2.i.0/2/24/A/CFLA/007

FITA

Kursa pārskats: 4 nedēļas ML ceļojuma

1. ML pamatkoncepcijas + datu sagatavošana (pabeigts)
2. Klasifikācijas pārskats + regresija (pabeigts)
3. Regresijas pārskats, klasterizācija + validācija (pabeigts)
4. **Pārskats + Gala projekta sākums (aktīvā)**
5. Gala projekta prezentācijas

Šonedēļ: Pārskats + gala projekta atrašana un plānošana.

1. nedēļa: Ievads un datu sagatavošana

Ko darījām	Mērķis
ML jēdziens	Dators mācās no datiem, prognozē nākotni
DataShop datu ielāde	Online shopping sesijas, ~12,000 rindas
EDA (eksplorācija)	Izpratne par iezīmēm un target
Tīrīšana un kodēšana	Missing values, kategorija → skaitļi
Standartizācija	StandardScaler — vidējais = 0, std = 1

Svarīgākais: Datu tīrīšana aizņēma ~40% laika. Profesionāļi to zina!

2. nedēļa: Klasifikācijas pārskats + Regresijas ievads

Jautājums	Atbilde	Modeļi	Metrikas
Vai klients pirks?	Jā/Nē (0/1)	Logistic Regression, Decision Tree, RF	F1, Precision, Recall

```
# Klasifikācija: Y ir kategorija (0/1)
from sklearn.linear_model import LogisticRegression
model = LogisticRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

Piemērs: "Šim klientam ir 82% varbūtība veikt pirkumu." Rezultāts: biznesa lēmums vai mārketinga darbība.

3. nedēļa: Regresija + Klasterizācija + Validācija

Jautājums	Atbilde	Modeļi	Metrikas
Cik naudas tērēs?	Skaitlis: EUR	Linear Regression, RF	MAE, RMSE, R^2
KĀDI ir klienti?	Grupas (0, 1, 2…)	K-Means	Elbow, Silhouette

```
# Regresija: Y ir skaitlis (EUR)
from sklearn.linear_model import LinearRegression
model = LinearRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

Piemērs: "Vidēji šī sesija ir vērta 45 EUR." + "Mums ir 3 klientu tipi: lojālie, izpētītāji, jaunpienācēji."

3. nedēļā arī: Modeļu validācija

Rīks	Ko tas risina?	Kāpēc svarīgi?
Cross-validation	Viena split neuzticamība	Vidējais CV F1 ± std
Pipeline	Data leakage	Scaler + Model vienkopus
GridSearchCV	Manuāla parametru meklēšana	Automātiska optimizācija

```
from sklearn.pipeline import make_pipeline
from sklearn.model_selection import cross_val_score, GridSearchCV

pipe = make_pipeline(StandardScaler(), RandomForestClassifier())
cv_scores = cross_val_score(pipe, X, y, cv=5, scoring='f1')
```

Šie rīki bija 3. nedēļas mājas darba B daļa. Jūs tos jau lietojāt praktiski!

Trīs ML tipi uz vienas lapas

Tips	Jautājums	Y kolonna	Modeļi	Piemērs
Klasifikācija	Kategorija?	Jā (0/1, A/B/C)	Logistic, RF	Pirks/nepirks
Regresija	Skaitlis?	Jā (EUR, grami)	Linear, RF	Pirkuma summa (EUR)
Klasterizācija	Grupas?	**NAV!**	K-Means	Klienta tips

Izvēles noteikums: Ir target Y? → Supervised (klasifikācija vai regresija). Nav Y? → Unsupervised (klasterizācija).

Cross-validation atkārtojums

Viens split nav pietiekams:

```
Eksperiments 1: Test F1 = 0.82
Eksperiments 2: Test F1 = 0.68
Eksperiments 3: Test F1 = 0.75
↓
Kurš rezultāts ir PATIESS?
```

Risinājums: 5-fold cross-validation

```
Fold 1: F1 = 0.72
Fold 2: F1 = 0.75
Fold 3: F1 = 0.71
Fold 4: F1 = 0.74
Fold 5: F1 = 0.73
↓
Vidējais: 0.73 ± 0.01 (UZTICAMS)
```

Cross-validation: katru datu punktu izmanto testā 1 reizi un trenē K-1 reizes. Vidējais rezultāts = patiesais sniegums.

Modeļu salīdzinājums pēc sniegума

Modelis	Priekšrocības	Trūkumi	Kad lietot
Logistic Regression	Ātrs, interpretējams	Vienkāršs	Baseline
Decision Tree	Vizualizējams	Pārmācīts	Izpratne
Random Forest	Precīzs, stabils	Lēnāks	Production
K-Means	Ātrs, intuitīvs	K manuāli	Segmentācija

Stratēģija: Vienmēr sāc ar vienkāršu modeli (Logistic), novērtē. Tad eskalē uz Random Forest vai XGBoost.

DataShop: vai projekts pabeigts?

1. Klasifikācija: Vai klients pirks?
Logistic / RandomForest (W1 HW + W2 pārskats)

2. Regresija: Cik EUR iztērēs?
Linear / RandomForest (W2 + W3 pārskats)

3. Klasterizācija: Kādi ir klienti?
K-Means, klasteris = 0/1/2 (W3)

4. Validācija: Cik drošs ir modelis?
Cross-validation, Pipeline (W3)

Šonedēļ: DataShop ir praktiski pabeigts. Nākamā nedēļa ir validācija un prezentācija.

Ko mēs šodien darām?

Šodienas plāns

1. Kursa apkopojums — trīs ML tipi + validācija vienā skatījumā
2. Modeļu salīdzinājums — kad lietot kuru algoritmu
3. Gala projekta ievads — prasības, dataset meklēšana, 4-punktu plāns
4. Praktiski padomi — kā sākt un kā izvairīties no kļūdām

Praktisks rezultāts: Gala projekta plāns ar izvēlētu datasetu un ML pieeju.

Gala projekts: jaunais mērķis

4. nedēļa: Projekta ATRAŠANA un PLĀNOŠANA

- Izvēlies jaunu datasetu (NE DataShop!)
- Definē problēmu (klasifikācija / regresija / klasterizācija)
- Plāno risinājumu

5. nedēļa: Prezentē gala projektu grupai.

```
Tava atbilde: 4-punktu plāns
1. Dataset: nosaukums, izmērs
2. Problēma: ko vēlies prognozēt?
3. ML tips: klasifikācija / regresija / klasterizācija
4. Metrikas: F1? RMSE? Elbow?
```

Dataseta meklēšanas padomi

Labas vietas atrast datus:

Kaggle
(kaggle.com) — 50,000+ publisku datasetu
UCI ML Repository
(archive.ics.uci.edu) — klasiski ML dataseti
Google Dataset Search
(datasetsearch.research.google.com)
GitHub
— atvērta koda projekti ar datiem

Prasības projektam:

- Vismaz 1000 rindu
- 5+ kolonnas
- Skaitliska + kategoriska kolonna
- **NEIZMANTOT DataShop!**

Ieteikums: Atlasīt domēnu, kas tevi interesē — medicīna, sports, klimats, sociālie tīkli, u.c.

4-punktu plāns: šablons

```
## Gala projekta plāns

**1. Dataset:**
- Nosaukums un avots
- Izmērs: [X] rindas × [Y] kolonnas
- Īss apraksts (max 2 teikumi)

**2. ML problēma:**
- Ko vēlies prognozēt vai saprast?

**3. ML tipu izvēle:**
- Klasifikācija / Regresija / Klasterizācija
- KĀPĒC šis tips?

**4. Novērtēšanas metrikas:**
- Klasifikācija: F1, Precision, Recall, Confusion Matrix
- Regresija: MAE, RMSE, R²
- Klasterizācija: Elbow method, Silhouette score
```

Līdz šonedēļas beigām: iesniedz šo plānu kā Markdown šūnu savā notebook. (vēlams, ne obligāti)

Piemērs: Iris Flowers projekta plāns

```
## Gala projekta plāns

**1. Dataset:**
- Iris Flower Dataset (UCI ML Repository)
- 150 rindas × 5 kolonnas
- Pūpolu izmēri (garums, platums) no trim sugām

**2. ML problēma:**
- Kura pūpolu suga ir visvairāk pieprasīta floristiem?

**3. ML tipu izvēle:**
- Klasifikācija (Species = setosa / versicolor / virginica)
- Mums ir pareizās atbildes jau datasetā

**4. Novērtēšanas metrikas:**
- F1 score, Confusion Matrix
- Cross-validation (cv=5)
- Feature importance
```

Šis plāns ir tikai 5 minūtes, bet ĻOTI svarīgs. Viņš strukturē idejas.

Dati, ko NEIZMANTOT

Pārāk vienkārši:

- Titanic — par daudz vienlīdzības
- Iris — tikai 150 rindas, 4 iezīmes
- Wine — tikai 178 rindas

Pārmērīgi sarežģīti:

- Attēli (ImageNet, MNIST) — deep learning
- Audio — signāla apstrāde
- Teksts (NLP) — transformeri

Labā vidusceļa zona: 1000–10,000 rindas, 5–20 kolonnas, tīri skaitliski vai vienkāršas kategorijas.

Timeline: 2 soļi

1. posms: Plānošana + sākums

- Atkārtot W1–W3 rezultātus (kursa sintēze)
- Atrast datasetu, aizpildīt 4-punktu plānu
- Veikt EDA + priekšapstrādes stratēģija
- Izveidot bāzes modeli (Pipeline + CV)

2. posm: Finalizēšana + prezentācija

- Pabeigt gala projektu (modeļi, validācija, interpretācija)
- 5–7 minūšu prezentācija grupai
- GitHub repozitorijs ar pilnu kodu

Gala projekta prasības: uzmetums

Obligāti ietvert:

1. Datu sagatavošana — eksplorācija, tīrīšana, kodēšana
2. Vismaz 2 salīdzināti modeļi — piem. RF vs XGBoost
3. Cross-validation — cv=5, ne viens split
4. GridSearchCV — hiperparametru optimizācija
5. Vizualizācija — grafiki, feature importance, confusion matrix
6. Biznesa interpretācija — ko modelis nozīmē reāli?
7. GitHub repository — kods, dati, dokumentācija

> **Svarīgākais:** Nav "perfekta" modeļa. Jūs pierādāt PROCESU — kā sistēmiski risināt ML problēmu.

Padomā: modelis vs. projekts

Jautājums:
Kāda ir atšķirība starp "labi F1 skaitļi" un "labs ML projekts"?

Tikai F1 = 0.85
— labi, bet nepilnīgi. Kā saņēmi? Cik stabils?

Projekts F1 = 0.82 ± 0.03 (CV)
— vairāk informācijas! Modelis ir stabils.

Projekts + validācija + biznesa stāsts
— pilnīgs! "Modelis identificē produktus, kas var būt nākamis dižpārdoklis."

Kāpēc mums vajag bāzes modeli (Baseline)?

Scenārijs:

```
Random Forest:  F1 = 0.83
XGBoost:        F1 = 0.84
↓
Vai XGBoost ir "labs"? Nav zināms!
```

Ar bāzes modeli:

```
Logistic Regression (baseline): F1 = 0.81
Random Forest:                  F1 = 0.83
(+0.02)
XGBoost:                        F1 = 0.84
(+0.03)
↓
Sarežģītāks modelis dod tikai +3%.
Varbūt Logistic ir labāks biznesa izvēle.
```

Noteikums: Vienmēr sāc ar vienkāršu modeli. Sarežģītāks ir vērtīgs TIKAI tad, ja tas būtiski pārspēj baseline.

Dataseta "sarkanā karoga" kontrolsaraksts

Pirms izvēlies datasetu — pārbaudi šos 3 brīdinājuma signālus:

#	Problēma	Piemērs	Ko darīt?
1	**Target leakage**	"Vai rīt līs?" + kolonna "rīt nokrišņi"	Izmet kolonnas, kas zina nākotni
2	**Augsta kardinalitāte**	5,000 unikālas vērtības (vārdi, ID)	Izmet vai grupē; nelieto One-Hot
3	**Ekstrēms disbalanss**	2 krāpšanas no 10,000 rindu	Izvēlies citu datasetu

Padoms: Ja tavs dataset atbilst kādam no šiem — labāk izvēlies citu. 30 min meklējot > 5 stundas cīnoties.

5. nedēļas vērtēšanas rubrika

Jūsu kods ir tikai 50% no vērtējuma. Pārējie 50% ir jūsu spēja izskaidrot biznesa vērtību.

#	Kritērijs	Svars
1	Datu sagatavošana — EDA, tīrīšana, kodēšana	★★
2	Vismaz 2 modeļi — salīdzināti ar metriku tabulu	★★
3	Cross-validation — cv=5, ne viena split	★★
4	GridSearchCV — hiperparametru optimizācija	★
5	Vizualizācija — grafiki, feature importance	★
6	**Biznesa interpretācija — ko modelis nozīmē reāli?**	★★★
7	Prezentācijas kvalitāte — skaidrs stāsts 5–7 min	★★
8	GitHub repo — kods, dati, README	★

Fokuss: Kamēr kodējat — domājiet par 6. punktu. Kādu biznesa lēmumu jūsu modelis var atbalstīt?

Praktiski padomi: pirmais solis

1. **Šodien vai rīt:** Atrodi 3 kandidātu datasetus. Pārbaudi pret sarkanajiem karogiem.

2. **Tajā pašā dienā:** Izlasi katru aprakstu (5–10 min). Izvēlies labāko.

3. **Rīt:** Uzraksti 4-punktu plānu + veic EDA + priekšapstrādes stratēģija.

4. **Trešā diena:** Izveido bāzes modeli (Pipeline + CV). Tas ir tavs atskaites punkts.

Gala rezultāts: Pilns week4_homework.ipynb ar sintēzi, plānu, EDA un bāzes modeli.

Paldies!

Jautājumi par projektu?

Nākamā nedēļa: Gala projekta prezentācijas

Jūs jau ESAT profesionāļi — tagad pierādiet to ar savu projektu.